

گزارش پیش‌بینی ریسک نکول کارت اعتباری

هدف مدل: برآورد احتمال نکول برای اولویت‌بندی بررسی انسانی؛ نه تصمیم خودکار تأیید یا رد اعتبار

1. موضوع پروژه

موضوع پروژه ما پیش‌بینی احتمال نکول پرداخت کارت اعتباری در ماه آینده است. مسئله را به‌صورت طبقه‌بندی دودویی حل کردیم، اما چون کلاس نکول اقلیت است، Accuracy را معیار اصلی قرار ندادیم و PR-AUC را معیار اصلی انتخاب کردیم. مدل نهایی Random Forest کالیبره‌شده است و با یک آستانه هزینه‌محور، پرونده‌های مشکوک را برای بررسی انسانی اولویت‌بندی می‌کند.

- تعداد داده‌ها: 30,000 مشتری
- Train Pool: 24,000 — Test: 6,000
- نرخ نکول تقریباً 22.1% در هر دو بخش
- هزینه فرضی FN پنج برابر FP

2. داده و توزیع متغیر هدف

نمودار توزیع کلاس هدف




تفسیر: کلاس نکول حدود 22.1% داده را تشکیل می‌دهد؛ بنابراین کلاس‌ها نامتوازن هستند و یک مدل که فقط کلاس غالب را پیش‌بینی کند می‌تواند Accuracy ظاهراً بالایی داشته باشد اما برای کشف نکول مفید نباشد.

پس نکته مهم، عدم‌توازن کلاس‌هاست. تقریباً یک‌پنجم مشتریان نکول کرده‌اند، بنابراین تمرکز ما روی معیارهای مناسب کلاس اقلیت بوده است.

3. مقایسه مدل‌های پایه

مدل‌های پایه ROC منحنی




تفسیر Random Forest در Validation با ROC-AUC برابر 0.7811 از Logistic Regression با 0.7677 بهتر است و Dummy با 0.50 صرفاً خط پایه را نشان می‌دهد.

پس Random Forest هم در ROC-AUC و هم در PR-AUC از Logistic بهتر بود؛ بنابراین برای ادامه مسیر، Random Forest را به‌عنوان کاندید اصلی انتخاب کردیم.

4. اثر پیش‌پردازش و مقادیر پرت


مقایسه پیش‌پردازش خام و مقاوم



تفسیر: تفاوت روش‌ها خیلی بزرگ نیست StandardScaler در PR-AUC با 0.5526 اندکی بهتر از RobustScaler با 0.5466 و Yeo-Johnson + Robust با 0.5468 بود. بنابراین مقادیر مالی شدید را حذف نکردیم؛ مدیریت مقاوم را به‌عنوان کنترل پایداری بررسی کردیم.

پس ما ردیف‌های مالی شدید را صرفاً به خاطر پرت بودن حذف نکردیم، چون ممکن است خودشان اطلاعات واقعی ریسک باشند. آستانه‌های پرت هم فقط از داده آموزش یاد گرفته شدند.


سقف اعتبار بر اساس کلاس هدف



تفسیر: این نمودار نشان می‌دهد توزیع سقف اعتبار بین دو کلاس یکسان نیست و می‌تواند در تفکیک ریسک نقش داشته باشد.

پس سقف اعتبار یکی از متغیرهایی است که الگوی آن بین نکول‌کنندگان و غیرنکول‌کنندگان متفاوت است؛ مدل از این تفاوت برای رتبه‌بندی ریسک استفاده می‌کند.

نرخ نکول بر اساس بیشترین تأخیر پرداخت




تفسیر: با افزایش سابقه تأخیر پرداخت، نرخ نکول تغییر محسوسی می‌کند؛ بنابراین سابقه پرداخت از مهم‌ترین سیگنال‌های ریسک است. از نظر کسب‌وکاری هم منطقی است: رفتار پرداخت گذشته اطلاعات مهمی درباره ریسک نکول آینده می‌دهد.

5. چرا Calibration انجام دادیم؟

منحنی کالیبراسیون روی Test


Test calibration (Brier=0.136)



تفسیر: هدف Calibration این است که احتمال پیش‌بینی شده فقط برای رتبه‌بندی نباشد و تا حد امکان معنای احتمالی قابل اتکاتری داشته باشد Brier Score. نهایی 0.1359 ثبت شد.

چون خروجی ما احتمال ریسک است، صرفاً Accuracy کافی نیست. باید احتمال‌ها هم قابل اتکا باشند؛ به همین دلیل Sigmoid Calibration را اعمال کردیم.


6. Threshold و هزینه خطا



هزینه بر حسب آستانه تصمیم

تفسیر: در سناریوی پروژه هزینه FN برابر 5 و هزینه FP برابر 1 فرض شده است. بنابراین آستانه پایین‌تر برای کاهش FN منطقی است، هرچند تعداد FP و حجم بررسی انسانی را بالا می‌برد. آستانه 0.5 برای این مسئله از نظر هزینه‌ای مناسب نیست؛ چون FN برای ما پنج برابر FP هزینه دارد. در Validation آستانه 0.145 کمترین هزینه را در سناریوی عملیاتی انتخاب‌شده ایجاد کرد.


انتخاب آستانه نهایی بعد از Calibration



تفسیر: آستانه 0.145 در Validation هزینه 3250، Recall برابر 0.7792 و نرخ ارجاع 47.07% ایجاد کرد. پس آستانه را روی Validation انتخاب کردیم، نه Test؛ فقط برای ارزیابی نهایی کنار گذاشته شد.

7. نتیجه نهایی Test

Test ماتریس خطای مدل نهایی روی




تفسیر: روی Test ، مدل 1017 مورد نکول واقعی را درست شناسایی کرد (TP) و 310 نکول واقعی را از دست داد (FN) در مقابل 1814 هشدار اشتباه (FP) داشت. این الگو نتیجه مستقیم انتخاب آستانه پایین‌تر برای کاهش FN است. این ماتریس خطا نشان می‌دهد مدل عمدهً Recall را بالا نگه داشته است. در کاربرد ما از دست دادن یک نکول مهم‌تر از ایجاد یک بررسی اضافه است.

نتایج نهایی : $Brier = 0.1359$ ، $F1 = 0.4892$ ، $Precision = 0.3592$ ، $Recall = 0.7664$ ، $ROC-AUC = 0.7791$ ، $PR-AUC = 0.5532$ ، نرخ ارجاع = 47.18%.


8. انتخاب ویژگی ها با Genetic Algorithm

GA و زیرمجموعه‌های All Features مقایسه



تفسیر: مدل **All Features** در **Validation** ، **PR-AUC** برابر 0.5515 داشت؛ **GA** با ویژگی‌های حساس 0.5390 و بدون آن‌ها 0.5372 ثبت کرد. بنابراین **GA** در این اجرا بهبود پیش‌بینی ایجاد نکرد و مدل نهایی با همه ویژگی‌ها حفظ شد. پس **GA** را فقط برای ادعای کاهش ویژگی اجرا نکردیم؛ نتیجه را با **All Features** مقایسه کردیم. چون افت داشت، آن را جایگزین مدل اصلی نکردیم.


پایداری GA در seed های مختلف



تفسیر: Jaccard انتخاب ویژگی در سه مقایسه حساس به seed ، بین 0.375 و 0.6875 بود؛ یعنی انتخاب ویژگی کاملاً پایدار نبود. پس علاوه بر ضعیف‌تر بودن AP ، انتخاب ویژگی GA هم کاملاً پایدار نبود؛ بنابراین برای نسخه نهایی ریسک اضافه نکردیم.


9. ممیزی زیرگروه‌ها

نکول بر اساس جنسیت Recall



تفسیر Recall: برای **SEX=1** حدود 0.781 و برای **SEX=2** حدود 0.756 است؛ اختلاف وجود دارد اما برای تفسیر آن باید نرخ پایه نکول و اندازه گروه‌ها هم در نظر گرفته شود. پس این نمودار را برای ممیزی و پایش مدل گزارش کردیم، نه برای نتیجه‌گیری عجولانه درباره تبعیض.

نکول بر اساس گروه سنی Recall



تفسیر Recall: در گروه‌های سنی متفاوت است؛ مثلاً برای گروه 20–24 حدود 0.832 گزارش شده است. اختلاف عملکرد زیرگروه‌ها باید در پایش دوره‌ای مدل بررسی شود. پس این تفاوت‌ها برای ما یک هشدار پایشی هستند؛ یعنی اگر مدل وارد محیط واقعی شود، باید عملکرد گروه‌ها جداگانه مانیتور شود.

10. آزمون حساسیت به نویز

در Validation AP, Controlled Noise از 0.556582 به 0.556631 تغییر کرد و Recall و Cost در آستانه نهایی ثابت ماندند. این اختلاف بسیار کوچک است؛ بنابراین در سناریوی نویز کنترل‌شده، مدل حساسیت شدیدی نشان نداد.

پس این آزمایش به ما می‌گوید نتیجه مدل با نویز کنترل‌شده‌ای که تعریف کردیم، به‌طور معناداری فرو نمی‌ریزد.

11. مقایسه مدیریتی $\text{Threshold} = 0.145$ و 0.5

Threshold	Cost	Review Rate	Recall	Precision	FN
0.145	3255	47.07%	77.92%	36.61%	293
0.5	4471	11.63%	35.95%	68.34%	850

تفسیر مدیریتی: آستانه 0.5 بررسی انسانی را بسیار کمتر می‌کند، اما 850 نکول را از دست می‌دهد. آستانه 0.145 با وجود افزایش بررسی‌ها، FN را به 293 کاهش می‌دهد و با فرض هزینه 5:1، هزینه کل Validation را پایین‌تر می‌آورد.

پس انتخاب آستانه یک انتخاب فنی صرف نیست؛ یک تصمیم عملیاتی است که بین ظرفیت بررسی انسانی و هزینه از دست دادن نکول تعادل ایجاد می‌کند.

12. پرسش های دفاع نهایی

1. چرا معیار اصلی شما برای این مسئله از Accuracy مناسب تر است؟
چون داده ما نامتوازن است و کلاس نکول اقلیت است؛ Accuracy می تواند با پیش بینی کلاس غالب گمراه کننده باشد. PR-AUC برای کیفیت رتبه بندی کلاس مثبت مناسب تر است.

2. کدام نوع خطا هزینه بیشتری دارد و آستانه انتخابی چگونه این هزینه را منعکس می کند؟
در پروژه هزینه False Negative برابر 5 و هزینه False Positive برابر 1 در نظر گرفته شده است. بنابراین False Negative پنج برابر False Positive هزینه دارد.
تابع هزینه:

$$\text{Cost} = 5 \times \text{FN} + 1 \times \text{FP}$$

بنابراین نمی توانیم Threshold را به صورت پیش فرض 0.5 قرار دهیم. با Validation، Threshold های مختلف را بررسی کردیم. پس 0.145 Threshold انتخاب شد. چون اگر Threshold را پایین بیاوریم، مشتریان بیشتری Flag می شوند.
احتمال بالاتر از 0.145 به عنوان آستانه عملیاتی برای ارجاع به بررسی انسانی استفاده می شود.

3. کدام مقادیر پرت مالی معتبر بودند و چگونه اثر آنها را بدون حذف مشتری کاهش دادید؟
در متغیرهای مالی مثل LIMIT_BAL، BILL_AMT و PAY_AMT مقادیر بسیار بزرگ مشاهده شد. اما نمی توانیم صرفاً به دلیل بزرگ بودن مقدار بگوییم داده اشتباه است؛ چون ممکن است نشان دهنده وضعیت واقعی مالی یک مشتری باشد.

پس مشتریان را به دلیل Outlier بودن حذف نکردیم.
ما Transformation های مناسب را بررسی کردیم.
و Robust Scaling را آزمایش کردیم.
اثر روش های مختلف را با Validation مقایسه کردیم.

4. تنظیم ابرپارامترها و انتخاب ویژگی چه تغییری در Recall کلاس نکول و کالیبراسیون ایجاد کرد؟
مدل پایه Random Forest روی Validation:

$$\text{PR-AUC} = 0.5515$$

$$\text{Brier} = 0.1744$$

بعد از تنظیم و Calibration:

$$\text{Validation PR-AUC} = 0.5566$$

$$\text{Validation Brier} = 0.1351$$

پس مهم ترین بهبود در Calibration دیده می شود.

پس GA باعث افزایش PR-AUC نشد و کاهش محدودی ایجاد کرد، اما تعداد Features را از 28 به حدود 8 تا 10 ویژگی کاهش داد. هدف GA فقط افزایش Performance نبود. برای کاهش پیچیدگی، بررسی پایداری Feature Selection و بررسی وابستگی به ویژگی‌های حساس استفاده شد.

5. ویژگی‌های حساس یا proxy‌های احتمالی چه اثری بر نتایج داشتند؟ حذف ویژگی‌های حساس باعث افت بسیار زیادی در Performance نشد، بنابراین مدل وابستگی شدیدی به آنها نشان نداد. با این حال، اختلاف Recall بین زیرگروه‌ها وجود دارد و به همین دلیل Subgroup Audit انجام دادیم. این تحلیل را به‌عنوان اثبات Fairness کامل در نظر نمی‌گیریم.

6. چه کنترل انسانی و پایش دوره ای برای استفاده واقعی الزم است؟ در استفاده واقعی، مدل نباید تصمیم‌گیرنده خودکار باشد و باید Human-in-the-loop داشته باشیم. عملکرد، Data Drift، Calibration، اختلاف عملکرد زیرگروه‌ها، نرخ False Negative و هزینه عملیاتی باید به‌صورت دوره‌ای پایش شوند. در صورت تغییر توزیع داده یا افت عملکرد، مدل باید دوباره اعتبارسنجی و در صورت نیاز Retrain و Threshold آن بازتنظیم شود.