

پروژه پیش بینی ریسک نکول کارت اعتباری

مدل سازی هزینه محور با کنترل سوگیری و تحلیل خطا

مشخصه	مقدار
تیم	تیم ۲
نوع مسئله	طبقه بندی دودویی و برآورد ریسک
مدت اجرا	یک هفته
ترکیب تیم	سه نفر
سطح پروژه	جمع بندی و توسعه مباحث آموزش داده شده

ماموریت پروژه

یک واحد مدیریت ریسک می خواهد احتمال نکول پرداخت در ماه آینده را برآورد کند تا پرونده های نیازمند بررسی انسانی را اولویت بندی کند. مدل نباید به عنوان ابزار خودکار پذیرش یا رد اعتبار معرفی شود. تیم باید بین کشف موارد پرریسک، هزینه هشدار اشتباه، کالیبراسیون احتمال و رفتار مدل در زیرگروه ها تعادل برقرار کند.

پرسش اصلی پروژه

آیا می توان احتمال نکول ماه آینده را با سابقه پرداخت و اطلاعات مالی برآورد کرد، بدون آنکه یک امتیاز کلی ضعف مدل روی گروه های کوچک یا هزینه خطا را پنهان کند؟

این شرح پروژه نتیجه مورد انتظار، محدودیت های علمی و شواهد لازم را تعیین می کند. ترتیب کار، انتخاب مدل ها، روش کاهش اثر نویز و نقاط پرت، فضای جستجوی ابرپارامترها و جزئیات پیاده سازی الگوریتم ژنتیک بر عهده تیم است. هر انتخاب باید با داده و نتیجه بخش اعتبارسنجی دفاع شود.

حدود اختیار تیم

بخش	موارد تعیین شده	موارد آزاد
مسئله	دیتاست، متغیر هدف و معیارهای حداقلی	صورت بندی دقیق کاربرد و فرض های قابل آزمون
آماده سازی	جلوگیری از نشت داده و حفظ نسخه خام	روش پاک سازی، تبدیل و مهندسی ویژگی
مدل سازی	وجود خط پایه، مدل تفسیرپذیر و مدل غیرخطی	خانواده مدل ها و تعداد آزمایش ها
تنظیم	جست وجوی مستند فقط روی آموزش و اعتبارسنجی	روش جست وجو، بودجه و فضای ابرپارامتر
انتخاب ویژگی	اجرای انتخاب ویژگی با الگوریتم ژنتیک	نمایش کروموزوم، عملگرها، کتابخانه و تنظیمات
ارزیابی	یک بار ارزیابی نهایی روی Test دست نخورده	نمودارها، تحلیل های تکمیلی و قالب ارائه

معرفی دیتاست

دیتاست Default of Credit Card Clients شامل اطلاعات ۳۰,۰۰۰ مشتری در تایوان است. ویژگی ها شامل سقف اعتبار، سن، کدهای جمعیت شناختی، وضعیت بازپرداخت شش ماهه، مبالغ صورتحساب و مبالغ پرداختی است. متغیر هدف وقوع یا عدم وقوع نکول در ماه بعد را نشان می دهد.

شرح	مشخصه
۳۵۰ UCI Machine Learning Repository با شناسه	منبع
default of credit card clients.xls	فایل اصلی
۳۰,۰۰۰ مشتری	تعداد نمونه
۲۳ ویژگی به علاوه شناسه و هدف	تعداد ویژگی
default payment next month با دو کلاس ۰ و ۱	متغیر هدف
عدد صحیح و پیوسته با چند کد دسته ای	نوع ویژگی
ندارد	مقادیر گم شده اعلام شده
CC BY ۴.۰	مجوز

صفحه رسمی و توضیحات دیتاست <https://archive.ics.uci.edu/dataset/۳۵۰/defaultofcreditcardclients>

لینک دانلود مستقیم فایل ZIP <https://archive.ics.uci.edu/static/public/۳۵۰/default/۲Bof/۲Bcredit/۲Bcard/۲Bclients.zip>

لینک های بالا در تاریخ ۳۰ سپتامبر ۲۰۲۶ بررسی شده اند. فایل خام باید بدون تغییر نگهداری شود و هر نسخه پردازش شده نام و توضیح جداگانه داشته باشد.

شناخت داده مورد انتظار

- ستون ID را از ویژگی های مدل جدا کنید و برای X1 تا X2۳ یک Data Dictionary با نام مفهومی و نوع واقعی تهیه کنید.
- کدهای SEX, EDUCATION, MARRIAGE و وضعیت های PAY را به عنوان عدد پیوسته تفسیر نکنید. مقادیر غیرمنتظره هر کد باید مستند شود.
- توزیع کلاس هدف، نسبت عدم توازن و تفاوت چند ویژگی کلیدی میان دو کلاس را گزارش کنید.
- مبالغ صورتحساب و پرداخت را با آمار مقاوم، Histogram یا مقیاس لگاریتمی مناسب تحلیل کنید و مقادیر بزرگ را بدون دلیل حذف نکنید.
- زمان مرجع هر گروه متغیر را توضیح دهید و مطمئن شوید هیچ ستون پس از ماه هدف ساخته نشده است.

شواهد تحلیلی الزامی

این بخش فهرست شواهدی است که گزارش باید ارائه کند و ترتیب اجرای کار را مشخص نمی کند.

صورت بندی تصمیم

- کاربرد مدل را اولویت بندی برای بررسی انسانی تعریف کنید و یک هزینه نسبی برای False Positive و False Negative پیشنهاد دهید.
- آستانه تصمیم بخشی از مدل است و باید فقط با Validation انتخاب شود. مقدار ۰.۵ بدون تحلیل هزینه، انتخاب توجیه شده محسوب نمی شود.

- احتمال پیش بینی شده، کلاس نهایی و اقدام عملیاتی پیشنهادی از یکدیگر تفکیک شوند.

تحلیل آماری و تصویری

- Mean, Median, Standard Deviation, Minimum, Maximum و صدک های ۲۵، ۵۰، ۷۵، ۹۰ و ۹۵ را برای LIMIT_BAL, AGE و گروه های PAY_AMT و BILL_AMT گزارش کنید.
- حداقل دو نمودار برای توزیع مبالغ، یک نمودار برای عدم توازن کلاس و دو مقایسه بین کلاس ها ارائه کنید.
- ارتباط سابقه تاخیر و نسبت پرداخت به صورتحساب با هدف را بررسی کنید. هر ویژگی مهندسی شده باید فقط از اطلاعات قبل از هدف استفاده کند.

مدل سازی

- یک Dummy Classifier یا خط پایه ساده، یک مدل تفسیرپذیر و دست کم یک مدل غیرخطی مقایسه شوند. انتخاب خانواده ها بر عهده تیم است.
- پردازش متغیرهای دسته ای، Scale و هر تبدیل مقاوم باید در Pipeline قرار گیرد تا در هر fold فقط از Train یاد گرفته شود.
- مدل نهایی باید علاوه بر رتبه بندی ریسک، کیفیت احتمال را با نمودار یا معیار کالیبراسیون بررسی کند.

کاهش اثر نویز و نقاط پرت

- مقادیر بسیار بزرگ مالی الزاماً خطا نیستند و ممکن است مشتری واقعی با رفتار متفاوت را نشان دهند. نویز این پروژه می تواند از کدگذاری نامنظم دسته ها، مبالغ صفر یا منفی با معنای خاص، نسبت های ناپایدار و برچسب های مرزی ناشی شود. تیم باید اثر این موارد را کاهش دهد، نه اینکه مشتریان دشوار را از داده حذف کند.
- مقادیر غیرمنتظره کدهای دسته ای و محدوده هر متغیر را با مستندات UCI تطبیق دهید و سیاست نگهداری، ادغام یا برچسب گذاری آنها را توضیح دهید.
- برای متغیرهای مالی دست کم دو راهبرد مقاوم مانند تبدیل توزیع، Robust Scaling، محدودسازی train based یا مدل مقاوم مقایسه شود.
- آستانه های نقطه پرت فقط با Train ساخته شوند. حذف رکورد فقط زمانی مجاز است که خطای داده با شواهد قابل دفاع باشد.
- حساسیت مدل به نویز کنترل شده در چند ویژگی یا به تغییر کوچک آستانه تصمیم بررسی شود تا شکنندگی مدل پنهان نماند.
- عملکرد خام و پردازش شده برای کلاس نکول و کلاس عدم نکول جداگانه گزارش شود.
- حذف خودکار هر رکوردی که از یک آستانه آماری عبور کرده قابل قبول نیست. تیم باید میان خطای ثبت، نویز اندازه گیری، رخداد نادر اما معتبر و نمونه خارج از دامنه کاربرد تفاوت بگذارد.

انتخاب ابرپارامترها

- استفاده از چند مقدار ثابت و انتخاب بهترین نتیجه روی Test پذیرفته نیست. تیم باید یک روش جست و جوی کارآمد و قابل بازتولید انتخاب کند؛ مانند جست و جوی تصادفی، successive halving، بهینه سازی بیزی یا TPE. انتخاب روش باید با اندازه داده، هزینه آموزش و نوع فضای جست و جوی سازگار باشد.
- یک Test طبقه بندی شده و دست نخورده کنار گذاشته شود. تنظیمات با Stratified Cross Validation یا Nested Cross Validation روی داده باقی مانده انجام گیرد.
- معیار اصلی جست و جوی پیش از اجرا تعیین شود. PR AUC، F1 کلاس نکول یا معیار هزینه محور بر Accuracy اولویت دارد؛ انتخاب نهایی باید توجیه شود.
- روش جست و جوی کارآمد و بودجه آن مشخص باشد. فضای ابرپارامترها باید از توزیع یا بازه معنادار استفاده کند، نه یک شبکه دلخواه کوچک.
- انتخاب آستانه تصمیم پس از تنظیم مدل و فقط با پیش بینی های Validation انجام شود.

در گزارش باید فضای جست و جو، بودجه محاسباتی، معیار بهینه سازی، نوع Cross Validation، seed، زمان اجرا و بهترین پیکربندی ثبت شود. نتیجه Test فقط پس از پایان تمام انتخاب ها محاسبه می شود.

انتخاب ویژگی با الگوریتم ژنتیک

انتخاب ویژگی با الگوریتم ژنتیک بخش مستقل و الزامی پروژه است. هدف فقط افزایش امتیاز نیست؛ تیم باید نشان دهد آیا می توان با تعداد ویژگی کمتر، عملکرد و پایداری قابل قبول به دست آورد.

- کروموزوم حضور یا عدم حضور ویژگی های اصلی یا گروه های زمانی آنها را نمایش دهد. گروه بندی شش ماه می تواند حفظ یا شکسته شود و تصمیم باید توضیح داده شود.
- تابع برازندگی از معیار اصلی Validation استفاده کند و برای تعداد ویژگی ها جریمه در نظر بگیرد.
- ویژگی های حساس جمعیت شناختی باید در دو سناریو بررسی شوند؛ با حضور برای ممیزی و بدون حضور برای مقایسه. استفاده یا حذف آنها باید همراه با تحلیل اثر باشد.
- فرآیند انتخاب ویژگی نباید Test را ببیند و باید در حداقل سه seed تکرار شود.
- ویژگی های منتخب از نظر معنای تجاری، پایداری و احتمال استفاده از proxy های حساس تحلیل شوند.

مقایسه	شاهد مورد انتظار
همه ویژگی ها	امتیاز اعتبارسنجی، امتیاز Test، تعداد ویژگی و زمان آموزش
ویژگی های منتخب ژنتیک	همان معیارها با فهرست ویژگی های منتخب
پایداری	هم پوشانی زیرمجموعه ها و پراکندگی امتیاز در حداقل سه seed
سادگی	توضیح روشن درباره ارزش حذف هر گروه ویژگی و هزینه کاهش یا افزایش پیچیدگی

اعتبارسنجی و معیارهای ارزیابی

داده زمان صریح هر رکورد را ندارد؛ بنابراین تقسیم طبقه بندی شده مناسب است. با این حال، تمام تبدیل ها، نمونه برداری احتمالی، انتخاب ویژگی و تنظیم ابرپارامتر باید درون fold های آموزش انجام شوند. Test برای انتخاب مدل، آستانه یا هزینه استفاده نمی شود.

- Precision.Recall.Confusion Matrix و F1 برای کلاس نکول و میانگین های Macro گزارش شود.
- ROC AUC و PR AUC ارائه شود و تفاوت کاربرد آنها در داده نامتوازن توضیح داده شود.
- Brier Score یا نمودار Calibration برای احتمال نکول بررسی شود.
- حداقل دو آستانه عملیاتی با هزینه یا نرخ بررسی انسانی مقایسه شوند.
- عملکرد برحسب زیرگروه های جنسیت و چند گروه سنی فقط برای ممیزی خطا گزارش شود و به عنوان اثبات عدالت کامل معرفی نشود.

مقایسه های حداقلی

حالت	هدف مقایسه
Dummy در برابر مدل ها	اثبات ارزش پیش بینی فراتر از نسبت کلاس
خام در برابر مقاوم سازی	اثر تبدیل مبالغ و کدهای نامنظم بر کلاس نکول
پیش فرض در برابر تنظیم شده	بهبود واقعی معیار اصلی و کالیبراسیون
همه ویژگی ها در برابر GA	تعادل دقت،سادگی و خطر proxyهای حساس
آستانه ها	تعادل False Negative.False Positive و بار بررسی انسانی

خطرها و خطاهای مفهومی

خطر	پیامد	شاهد کنترل خطر
Accuracy غالب	نادیده گرفتن نکول های از دست رفته	PR AUC.Recall و ماتریس خطا
تنظیم روی Test	برآورد خوش بینانه	Test قفل شده و ثبت زمان ارزیابی نهایی
کد دسته ای به صورت پیوسته	ترتیب و فاصله ساختگی	پردازش صریح دسته ها در Pipeline
حذف مشتریان پرت	مدل ظاهراً بهتر اما غیرواقعی	تحلیل معتبر بودن مقادیر و مقایسه مقاوم
سوگیری جمعیت شناختی	آسیب نابرابر و ریسک حقوقی	ممیزی زیرگروه و محدودیت کاربرد
تفسیر به عنوان تصمیم اعتباری	استفاده پرخطر خارج از دامنه	تعریف بررسی انسانی و منع تصمیم خودکار

معیار پذیرش پروژه

۱. متغیر هدف، کلاس مثبت و هزینه نسبی خطاها پیش از مدل سازی تعریف شده باشد.

۲. Accuracy معیار اصلی نباشد و عملکرد کلاس نکول جداگانه گزارش شود.

۳. اثر نویز، کدهای نامنظم و نقاط پرت مالی با مقایسه خام و مقاوم تحلیل شود.

۴. ابرپارامترها و آستانه تصمیم بدون استفاده از Test انتخاب شوند.

۵. انتخاب ویژگی ژنتیکی همراه با جریمه تعداد ویژگی، پایداری و تحلیل proxy های حساس باشد.

۶. احتمال های مدل از نظر کالیبراسیون بررسی شوند.

۷. گزارش صریحاً اعلام کند که این مدل برای رد یا قبول خودکار اعتبار مناسب نیست.

پرسش های دفاع نهایی

۱. چرا معیار اصلی شما برای این مسئله از Accuracy مناسب تر است؟

۲. کدام نوع خطا هزینه بیشتری دارد و آستانه انتخابی چگونه این هزینه را منعکس می کند؟

۳. کدام مقادیر پرت مالی معتبر بودند و چگونه اثر آنها را بدون حذف مشتری کاهش دادید؟

۴. تنظیم ابرپارامترها و انتخاب ویژگی چه تغییری در Recall کلاس نکول و کالیبراسیون ایجاد کرد؟

۵. ویژگی های حساس یا proxy های احتمالی چه اثری بر نتایج داشتند؟

۶. چه کنترل انسانی و پایش دوره ای برای استفاده واقعی لازم است؟

خروجی های موردنیاز

- Jupyter Notebook کامل که از ابتدا تا انتها بدون خطا اجرا شود و خروجی های اصلی در آن باقی مانده باشد.
- گزارش PDF بین ۶ تا ۸ صفحه شامل تصمیم ها، شواهد، مقایسه ها، خطر ها و محدودیت ها؛ گزارش نباید نسخه چاپی تمام کد باشد.
- فایل README.md شامل لینک منبع داده، روش اجرا، نسخه کتابخانه ها، seed ها، زمان تقریبی اجرا و مسئولیت هر عضو.
- پوشه data با نسخه خام دست نخورده و در صورت نیاز نسخه پردازش شده با توضیح روشن درباره تغییرات.
- فایل results.csv یا جدول معادل شامل تمام آزمایش های اصلی، معیار اعتبارسنجی، معیار Test، تعداد ویژگی و زمان اجرا.
- ارائه ۱۰ دقیقه ای با مشارکت هر سه عضو و پاسخ به پرسش های دفاع نهایی.

تقسیم مسئولیت

تیم می تواند مسئولیت ها را به دلخواه تقسیم کند، اما هر عضو باید هم در کد و هم در تحلیل مشارکت قابل مشاهده داشته باشد. در README مسئول هر بخش و بازبین آن مشخص شود. بخش های جداسازی داده، کنترل نشت و نتیجه نهایی باید دست کم توسط یک عضو دیگر بازبینی شوند.